

超啟發演算法 (Metaheuristics / Hyper-heuristics) 2020–2026

研究方向：不只是「換一種動物」

2020 年以後，這個領域在方法論上真正有進展的，並不是新的隱喻型演算法，而是**「讓演算法本身變成被學習或被設計的對象」**。主要有三條線：強化學習 (RL) 或元學習控制搜尋過程 (MetaBBO、動態演算法配置)、大型語言模型 (LLM) 自動生成啟發式程式碼 (FunSearch、EoH、ReEvo)，以及以 irace、IOHprofiler、模組化框架為基礎的自動化演算法設計與嚴謹基準測試。量子方向目前可以研究，但不宜當成「會帶來效能優勢」的主張；RL 方向則已經成熟到可以直接投入論文研究。

TL;DR

- **RL 可以用，而且是目前最成熟的方向之一**：已經有 EJOR、NeurIPS 等級的代表作 (如 Q-learning 選運算子、DRL 超啟發式、MA-DAC 用多智能體 RL 配置 MOEA/D)，也有 MetaBox 這類標準化基準平台。主要風險在於訓練成本、泛化能力，以及對手 baseline 是否調校公平。
- **量子目前「可研究、難宣稱優勢」**：量子啟發演算法 (QIEA) 本質上是古典的機率模型 EA，不是量子計算；真實硬體上的 QAOA / 量子退火至今沒有在實務規模的最佳化問題上建立公認的量子優勢。最有說服力的一篇結果 (Science Advances 2024，LABS 問題) 也只是理想化無雜訊模擬，而且其優勢要依賴容錯硬體才成立。相對務實的切入點是「用超啟發式最佳化量子電路或 QAOA 參數」。
- **其他值得投入的方向**：LLM 驅動的自動化啟發式設計、自動化演算法設計與配置 (irace / 模組化框架)、景觀分析與演算法選擇、演化多任務、理論 runtime analysis，以及基準測試與可重現性。對 WSN 研究生來說，「MAPPO / MARL 控制族群式搜尋」目前在 WSN 上幾乎還沒有深度 MARL + 元啟發式的同儕審查成果，算是一個真正的空白，但前提是要用嚴謹的基準與消融實驗證明價值。

背景：學界對「隱喻型演算法氾濫」的批評

- **Sörensen (2015，ITOR 22(1):3–18)** 〈Metaheuristics—the metaphor exposed〉形容組合最佳化領域出現了「a true tsunami of 'novel' metaheuristic methods」，並主張這股潮流讓領域偏離科學嚴謹性：新隱喻不等於新方法。 (wiley)
- **Camacho-Villalón、Dorigo、Stützle 的一系列元件分析**：ANTS 2020 論文指出灰狼 (GWO)、螢火蟲 (FA)、蝙蝠 (BA) 演算法「are not novel, but a reiteration of ideas introduced first for particle swarm optimization」；ITOR (ulb) 2023 (30(6):2945–2971) 把分析擴大到灰狼、飛蛾撲火、鯨魚、螢火蟲、蝙蝠、蟻獅六種，結論是它們的唯一新意只是「six different terminologies」；另有布穀鳥搜尋 (C&OR (researchgate) (arxiv) 2022) 與智慧水滴 (Swarm Intelligence 2019) 的分析。 (arxiv)
- **期刊政策**：Aranha 等人 (2022，Swarm Intelligence 16(1):1–6) 的公開信〈the elephant in the room〉(據《Intelligent Computing》的整理，集結了約 100 位研究者) 呼籲各期刊比照 Journal of Heuristics、Swarm Intelligence、ACM TELO 的作法，拒收新隱喻演算法，除非作者：(i) 用標準最佳化術語描述方法；(ii) 證明有真正新概念；(iii) 有科學依據說明為何使用隱喻；(iv) 以最先進基準測試做公平比較。《Intelligent

Computing》的〈Designing New Metaheuristics: Manual Versus Automatic Approaches〉整理指出 4OR 與 Engineering Applications of Artificial Intelligence 也有類似政策，EAAI 的 Aims & Scope 更明言「Papers on new metaphor-based metaheuristics are very rarely accepted」。EJOR 五十週年回顧〈Fifty years of metaheuristics〉更直言「metaphor-based metaheuristics are simply bad science」。[sciencedirect](#)

- **意涵：**以隱喻為主要賣點的投稿，在頂尖期刊（TEVC、EJOR、ECJ、TELO）的接受空間已經大幅縮小。研究生若要在元啟發式領域發表，應該把貢獻寫成「元件、機制、學習策略或理論性質」，而不是寫成「新動物」。

方向一：強化學習 × 元啟發式 / 超啟發式（重點評估）

1.1 方法分類

類別	RL 做什麼	代表作	成熟度
參數自適應控制 (parameter control)	每一代依搜尋狀態調整 F、CR、慣性權重等	DE-DDQN、LDE、RLEPSO、GLEET (均收錄於 MetaBox) (github) (arxiv)	高
自適應運算子選擇 (AOS)	在多個突變 / 交配 / 鄰域運算子中選擇	Karimi-Mamaghan 等 (EJOR 2023, Q-learning 嵌入 Iterated Greedy 解 PFSP) ; Johnn 等 (OLA 2023, 圖 RL 選 ALNS 運算子) (ed) (arxiv)	高
超啟發式的低階啟發式 (LLH) 選擇	高階策略從 LLH 集合中挑選	Zhang、Bai、Qu 等 (EJOR 2022, DDQN 超啟發式處理不確定性) ; (sciencedirect) Kallestad 等 (EJOR 2023, DRLH 通用框架) ; Kletzander & Musliu (AAAI 2023, LAST-RL) (arxiv +3)	中高
Learning to optimize / MetaBBO	在問題分佈上元訓練一個控制最佳化器的策略，希望泛化到新問題	MetaBox (NeurIPS 2023 D&B)、MetaBox-v2、MetaBBO 綜述 (arXiv 2411.00625)、LES / LGA (元學習出的 ES / GA) (arxiv +3)	中
神經組合最佳化 (NCO)	DRL 直接學習建構式或改進式策略	Kool 等 (ICLR 2019 注意力模型)、POMO (NeurIPS 2020) ; 綜述見 Bengio、Lodi、Prouvost (EJOR 2021, 290(2):405–421) (arxiv)	中 (泛化仍是瓶頸)
多智能體 RL (MARL) × 族群式搜尋	多個 agent 分別控制不同超參數，或每個個體 / 子族群各是一個 agent	MA-DAC (NeurIPS 2022)、Seq-MADAC (NeurIPS 2025)、DeepHive (arXiv 2023) (arxiv +2)	初期

1.2 代表性工作重點

- **Karimi-Mamaghan 等 (EJOR 2023, 304:1296-1330)**：用 Q-learning 在 Iterated Greedy 中線上選擇擾動運算子與強度（移除並重插的工件數），是「RL 選運算子」在 OR 頂刊的典型範例。[\(arxiv\)](#)
- **Kallestad 等 (EJOR 2023) 的 DRLH**：用深度 RL 挑選啟發式，報告指出在幾乎所有問題變體上，都能以更少的迭代次數得到比 ALNS 與均勻隨機選擇更好的結果。[\(sciencedirect\)](#)
- **MetaBox (Ma 等, NeurIPS 2023 Datasets & Benchmarks)**：第一個專門評估 MetaBBO-RL 的平台，包含 300 個以上的問題實例（54 個合成實例，問題定義取自 COCO；280 個真實實例，取自 Protein-Docking benchmark）、19 個 baseline，並提出 AEI（整體表現）與 MGD（元泛化衰減）等標準化指標。MetaBox-v2 ([arXiv 2505.17745](#)) 進一步納入 RL 以外的學習範式，涵蓋 18 個合成 / 真實任務（1900 個以上實例），橫跨單目標、多目標、多模態與多任務最佳化，MetaBBO baseline 從 8 個擴充到 23 個，並以平行化將訓練 / 測試時間縮短 10-40 倍；它也觀察到各 baseline 在不同測試集間的泛化差異很大。這一點很重要：「在訓練分佈上贏」不等於「真的學會最佳化」。
- **MA-DAC (Xue 等, NeurIPS 2022)**：把具有多種超參數的演算法動態配置，建模為合作式多智能體 MDP，「one agent working for one type of configuration hyperparameter」。應用在 MOEA/D 上時，以 VDN 同時學習權重、鄰域大小、再生運算子類型與運算子參數四類超參數，表現優於規則式、多臂吃角子老虎機與單智能體 RL 的配置方式。[\(neurips\)](#) [\(arxiv\)](#)
- **Seq-MADAC (Lu 等, NeurIPS 2025)**：考量參數之間的相依性，提出 sequential advantage decomposition network (SADN)，並把 MAPPO、QMIX、HAPPO、HASAC、VDN 列為 baseline，在 MOEA/D 上的 IGD 平均排名最佳（例如 6 維 DTLZ2：3.809e-02，vanilla MOEA/D 為 4.593e-02）。[\(arxiv\)](#)這是「MAPPO 用來配置演化演算法」目前最直接可引用的同儕審查對照。
- **DeepHive (Ikponmwoba & Owoyele, arXiv 2023, 預印本)**：把每個粒子當作共享同一策略的 PPO agent，在 2D cosine mixture 函數上達到門檻值需要 130 次函數評估，GENOUD 則需要 350 次。[\(arxiv\)](#)問題維度小、尚未經過同儕審查，只適合當作概念參考。

1.3 優點、缺點與開放問題

優點：把「手調參數與運算子排程」轉成可學習的決策問題；策略可以跨實例重複使用；和超啟發式「高階選擇器 + 低階啟發式」的架構天然相容。

缺點與常見陷阱：

1. **訓練成本**：MetaBBO 需要在大量問題實例上元訓練，對昂貴問題（例如 WSN 模擬）不一定划算。
2. **泛化**：NCO 與 MetaBBO 都有明顯的分佈外衰退。Garmendia 等人在 ACM TELO（2024）發表〈Applicability of neural combinatorial optimization: A critical view〉，[\(arxiv\)](#)對 NCO 的實用性提出批判性檢視。

3. 比較公平性：很多「RL-增強 XX 演算法」的論文，只和未調校的舊版演算法比較，重蹈隱喻型論文的覆轍。應該和 irace 調校過的 baseline 以及 CEC / BBOB 冠軍演算法（如 L-SHADE 系列、jSO）比較。
4. 狀態與獎勵設計缺乏共識，credit assignment 在族群搜尋中尤其困難。
5. Q-learning 綜述（WIREs 2024）收錄的大量論文，其實是「Q-learning + 某隱喻演算法」，學術增量有限。([wiley](#))

開放問題：能跨問題類別泛化的狀態表徵（例如用景觀特徵或 attention 自動學習，像 RLDEAFL）；([github](#))離線 RL 或從搜尋軌跡學習；MARL 中多個參數之間的相依與協調（Seq-MADAC 正是在處理這一點）；([arxiv](#))可解釋性。

1.4 結論：RL「可以應用」嗎？

可以，而且證據充分。在運算子選擇、參數控制、LLH 選擇上，已有 EJOR、NeurIPS、AAAI 等頂級發表，也有標準化基準（MetaBox）。MARL 則處在「頂會已有少數框架論文，應用端近乎空白」的階段，適合研究生切入，但要把問題說清楚：為什麼需要多智能體？通常理由是多個異質超參數或多個子族群之間需要協調，或者問題本身是分散式的。如果單一 agent 能做到，審稿人會質疑 MARL 的必要性。

方向二：量子相關方向（重點評估）

2(a) 量子啟發演算法（在古典電腦上執行）

- 代表作是 Han & Kim 的 QIEA（IEEE TEVC 2002, 6(6):580-593），([arxiv](#))用「Q-bit 機率振幅 + 旋轉門」表示族群分佈。Zhang（Journal of Heuristics 2011）的綜述明確定義 QIEA 是「a new evolutionary algorithm for a classical computer rather than for quantum mechanical hardware」；([acm](#))PMC 上的回顧也指出它「is not actually a quantum algorithm」。([nih](#))
- 評估：QIEA 本質上接近分佈估計演算法（EDA）或機率模型式 EA，「量子」一詞多半只是隱喻，和上述隱喻批評屬於同一類風險。它不會帶來任何量子加速，適應度評估仍然全在古典電腦上完成。不建議把它當成「量子研究」。([nih](#))若要使用，應該用 EDA 的語言描述，並和 cGA、PBIL、CMA-ES 等公平比較。

2(b) 在真實量子硬體上執行的方法

- QAOA：目前最有份量的正面證據是 Shaydulin 等（Science Advances 2024）。在 LABS 問題上， $p=12$ 的 QAOA 求解時間（TTS）成長率為 1.46^N ，配合量子最小值搜尋（QMF）降為 1.21^N ，優於最佳古典啟發式的 1.34^N 。([science](#))但要注意三點：這是最多 40 qubits 的無雜訊模擬；QAOA 單獨使用時並沒有優勢；QMF 必須依賴容錯量子電腦。([researchgate](#))作者自己也說不主張 QAOA 是理論上最佳的演算法，而且古典的 Memetic Tabu 也可能被進一步加速。([science](#))
- 量子退火（D-Wave）：D-Wave 在 Science 發表的「beyond-classical」成果，主題是量子模擬（自旋玻璃動力學），不是最佳化，而且已經受到 EPFL（t-VMC，Mauron & Carleo 2025）與 Flatiron Institute 計算量子物理中心 Joseph Tindall 團隊（與波士頓大學合作，以 belief-propagation 張量網路方法發表於 Science）的古典模擬挑戰；D-Wave 則回應這些案例仍「remain beyond the reach of current classical methods」。針對「近

似最佳化出現量子擴展優勢」的主張 (Munoz-Bauza & Lidar · PRL 134, 160601, 2025) · 〈Toward quantum scaling advantage in approximate optimization〉 (arXiv 2505.22514) 以 GPU 版 simulated bifurcation machine 在多達約 4×10^4 個變數的實例上測試，結論是現有量子退火機「unlikely to exhibit a clear scaling advantage over SBM-like solvers」。

- **實務基準**：Scientific Reports (2025) 對 D-Wave 混合求解器的基準研究結論是，它只在「a limited set of real-world problems」上與古典方法具競爭力；以機組排程為例，D-Wave 平均需要 5 秒，Gurobi 不到 1 秒就找到最佳解。(nature)投資組合的大規模基準 (arXiv 2509.17876) 也發現，問題專用的古典啟發式在固定時間內解的品質優於量子方法，而 Gurobi 在大型實例上快 1000 倍以上。(arxiv)
- **學界共識**：Abbas 等 40 多位作者 (Quantum Optimization Working Group，通訊作者為 IBM Quantum 的 Stefan Woerner) 在 Nature Reviews Physics (2024, 6(12):718–735) 的綜述，把重點放在「哪裡可能有量子優勢」與建立基準；Koch 等人推出 Quantum Optimization Benchmarking Library (QOBLIB，「Intractable Decathlon」，涵蓋十類困難組合問題)，目的就是追蹤量子方法「朝向」優勢的進展。(nature)(arxiv)這本身就說明優勢尚未確立。NISQ 的主要限制包括：qubit 數量與連接度、雜訊與電路深度、QUBO 轉換造成的變數膨脹 (例如約束需要用懲罰項處理)，以及 barren plateau (McClean 2018 ; Cerezo 2021)。(arxiv)(nature)

2(c) 用超啟發式最佳化量子電路或量子演算法參數

- **量子架構搜尋 (QAS)**：用演化、RL 或 NAS 方法搜尋參數化量子電路 (ansatz) 的結構。代表作包括 Du 等 (npj Quantum Information 2022)，指出 QAS 可以緩解雜訊與 barren plateau 的影響，並優於預先指定 ansatz 的 VQA；(nature)Ding & Spector (2022) 的演化 QAS；(arxiv)以及 Martyniuk 等的 QAS 綜述 (2024)。也已經有研究用多智能體 RL 做分散式 QAS (arXiv 2511.22708)。(arxiv)
- **QAOA / VQE 參數最佳化**：量子電路的參數地形崎嶇、梯度估計成本高又有雜訊，是 CMA-ES、DE 等無梯度黑箱最佳化器的典型應用場景 (例如 arXiv 2309.16796 比較了嵌入元啟發式最佳化器的 QAOA)。(arxiv)
- **評估**：這是三個子方向中最務實的一個。你的貢獻在古典端 (搜尋演算法)，可以完全在模擬器上驗證，也不必宣稱量子優勢；而且量子電路的地形正好適合用景觀分析、代理模型等工具研究。

2.4 結論：量子「可以應用」嗎？

- **作為研究題目**：可以，但要選對子方向。(c) 最可行；(b) 適合做「誠實的基準研究」(和調校過的古典啟發式及 Gurobi 公平比較)；(a) 學術價值有限。
- ****作為效能主張**：目前不行。**截至 2026 年，沒有公認證據顯示量子硬體在實務規模的最佳化問題上勝過最好的古典方法。(postquantum)(medium)對 WSN 研究生而言，把 WSN 部署或叢集問題寫成 QUBO 丟到 D-Wave 上跑，大概只能得到「可以跑、但比古典慢或差」的結論，除非研究重點本身就是基準評估。

方向三：其他重要近期方向

3.1 LLM 自動設計 / 演化啟發式

- **核心概念**：把「啟發式程式碼」當作個體，由 LLM 擔任突變與交配運算子，再由評估器計算適應度，形成 LLM-based evolutionary program search。
- **代表作**：FunSearch (Romera-Paredes 等, Nature 2024, island 模型，在 cap set 等問題上有新發現)；EoH (Liu 等, ICML 2024, 同時演化「thought」與程式碼)；ReEvo (Ye 等, NeurIPS 2024, 用 LLM「反思」提供 verbal gradient)；後續有 HSEvo (AAAI 2025)、MCTS-AHD、EoH-S (演化啟發式集合)、MEoH (多目標)，以及 LLaMEA (van Stein & Bäck) 直接生成完整的元啟發式。(arxiv +3) 社群也有 LLM4AD 統一平台。
- **開放問題**：研究發現 EoH 的多樣性較高，但目標值不穩定，ReEvo 目標值好但多樣性不足 (HSEvo 的分析)；(aai) 另有研究 (arXiv 2407.10873) 強調，**演化搜尋本身**才是這類方法有效的關鍵，不是 LLM 單次生成。其他問題還包括 LLM 呼叫成本、資料汙染與可重現性 (依賴閉源模型版本)，以及生成的啟發式是否真的新穎、還是 LLM 重述了已知方法。值得注意的是，LLM 也可能「生成」出換皮的隱喻演算法。2026 年 npj (Nature 旗下) 的〈Beyond metaphors〉一文正是在討論這類設計流程如何避開隱喻陷阱。(nature)

3.2 自動化演算法設計與配置 (AAD / AC)

- **irace** (López-Ibáñez 等, Operations Research Perspectives 2016, 3:43-58) 以 iterated racing 自動配置參數，(arxiv) 是這個領域的標準工具；(alphaxiv) (dntb) SMAC、Hyperband 等屬於同類工具。(arxiv)
- **元件化框架 + 自動組裝**：把演算法拆成可組合的模組，再用配置器搜尋組合。例子有 PSO-X (Camacho-Villalón)、(alphaxiv) modular CMA-ES (van Rijn 等 2016)、ParadisEO，以及 ParadisEO + irace + IOHprofiler 的整合流程 (Aziz-Alaoui、Doerr、Dreo 2021)。(arxiv) (arxiv) Stützle 與 López-Ibáñez 在 Handbook of Metaheuristics (2019) 的〈Automated design of metaheuristic algorithms〉一章，以及〈Designing New Metaheuristics: Manual Versus Automatic Approaches〉，都主張用自動設計取代手工的隱喻式設計。(arxiv) (science)
- **意涵**：這是「反隱喻」陣營提出的正面替代方案：與其發明新動物，不如定義設計空間，讓機器去搜尋。

3.3 景觀分析 (ELA) 與演算法選擇

- **Exploratory Landscape Analysis** 從少量取樣點計算問題特徵 (如 flacco 套件)，再用機器學習為每個實例選擇演算法。代表作是 Kerschke & Trautmann (ECJ 2019, 27(1):99-127) 與 Kerschke、Hoos、Neumann、Trautmann 的綜述 (ECJ 2019, 27(1):3-45)。(springer)
- **近期進展與問題**：ELA 特徵對取樣策略非常敏感 (PPSN 2020)；深度學習特徵 (DoE2Vec、Deep-ELA) 開始出現；(arxiv +2) 景觀特徵也被當作 RL 的狀態輸入 (如 RLDEAFL)。(github) 這讓 ELA 成為連接「演算法選擇」與「RL 控制」的橋梁。

3.4 代理模型輔助 / 昂貴最佳化

- **核心**：當一次評估需要模擬或實驗（例如大規模 WSN 模擬、電磁模擬）時，用 Gaussian process、RBF、神經網路等代理模型取代部分真實評估，並用填充準則（infill criteria）決定何時做真實評估。
- **趨勢**：data-driven EA（離線與線上資料）、代理模型與 MetaBBO 結合（MetaBox 已收錄 Surr_RLDE 這類方法）、(github)高維下的代理模型可擴展性。**開放問題**包括高維（>100 維）代理模型失準，以及昂貴多目標問題中 infill 準則的選擇。

3.5 大規模與高維最佳化

- 協同演化分解（變數分組）、多族群、元學習出的最佳化器（LES、LGA 在 MetaBox 中歸類為 large-scale global optimization）。(github)開放問題是如何自動偵測變數交互作用，以及在固定評估預算下的擴展性。

3.6 多目標與演化多任務（EMT）

- **EMT**：用單一族群同時解多個任務，並在任務之間轉移知識。奠基作是 Gupta、Ong、Feng 的 MFEA（IEEE TEVC 2016, 20(3):343-357），後續有 MFEA-II（TEVC 2020, 24(1):69-83，線上估計轉移參數）；Wei 等人的綜述發表於 TEVC 2022（26(5):941-960）；Gupta 等在 IEEE CIM（2022）整理了「Half a dozen real-world applications」。(acm +2)
- **核心開放問題**：負轉移（negative transfer）——如何判斷何時轉移、轉移什麼。這可以和 RL 或 MARL 結合（讓 agent 決定轉移強度）。多目標方面，MOEA/D 是 MA-DAC 與 Seq-MADAC 的實驗平台，說明「多目標 + 學習式配置」是活躍的交叉點。(arxiv)

3.7 理論分析（runtime analysis）

- 以期望執行時間分析 EA 的效能，近年重大突破是首次對 NSGA-II 等實用多目標 EA 做嚴格的 runtime 分析（Zheng、Liu、Doerr，AAAI 2022），之後有大量後續工作。理論結果已經開始回饋到演算法設計，例如 fast GA（Doerr 等，GECCO 2017）的重尾突變。(arxiv)對應用型研究生而言，理論不一定是主線，但可以用來判斷哪些「新機制」其實有理論依據。

3.8 基準測試與可重現性

- IOHprofiler（Doerr、Wang、Ye、van Rijn、Bäck 2018；IOHexperimenter + IOHalyzer）提供 anytime 效能分析與固定預算 / 固定目標比較；(arxiv)(arxiv)此外還有 COCO/BBOB、Nevergrad，以及 MetaBox（針對 MetaBBO）與 QOBLIB（針對量子最佳化）。
- 「基準測試」本身也成了反隱喻的工具：GECCO 2024 的〈Large-Scale Benchmarking of Metaphor-Based Optimization Heuristics〉大規模檢視隱喻演算法的實際表現。(acm)

對 WSN 研究（MAPPO × Search Economics 構想）的具體建議

1. 先確認 Search Economics 的定位：Search Economics 由 Chun-Wei Tsai（中山大學）提出，原始發表為 IEEE SMC 2015 的〈Search Economics: A Solution Space and

Computing Resource Aware Search Method)》。[\(nsysu\)](#)它把解空間切成子空間，再依各子空間的「expected value」分配搜尋者。[\(missouri\)](#)WSN 相關應用有部署 (Computer Networks, vol. 101, 2016) 與叢集 (IEEE SMC 2017)，也有 CEC 2020 單目標實數最佳化版本 (作者自述在 CEC 2017 測試集上優於 jSO、L-SHADE-RSP 等，尚需獨立驗證) 以及 TEVC 2024 的免訓練 NAS 應用。[\(missouri +2\)](#)它的核心是「預算分配」而不是動物隱喻，這在論文定位上是加分。

2. **MAPPO 與 SE 的自然結合點**：SE 的「子空間 = 區域、搜尋者 = 資源分配」結構，很適合 MARL 的「一個子空間 (或一類超參數) 一個 agent、集中訓練分散執行 (CTDE)」。[\(arxiv\)](#)可以讓 agent 學習子空間的投資決策與運算子選擇，取代手工的 expected value 公式。MA-DAC 與 Seq-MADAC 提供了直接可引用的方法論前例；Seq-MADAC 已把 MAPPO 列為 baseline，你可以以此為對照。[\(arxiv\)](#) [\(arxiv\)](#)
3. **現況空白**：目前能找到的 WSN 相關工作，多半是「每個節點一個表格式 Q-learning agent + 元啟發式」(如 Obreja, Mathematics 2025，以 binary Hunger Games Search 初始叢集頭與路由)，或「單一 DRL agent + 隱喻混合演算法」(如 Scientific Reports 2026 的 DRL + WOA-GWO 多路徑路由，報告封包傳遞率 97.8%)。尚未看到以 [\(doi\)](#) [\(nature\)](#) **MAPPO 類深度 MARL 控制元啟發式來解 WSN 最佳化的同儕審查成果**，這是真正的切入點。但要避免做成「MAPPO + 又一個動物演算法」。
4. **實驗設計要點**：(i) baseline 應包含 irace 調校過的 SE、L-SHADE / CMA-ES，以及單智能體 PPO 控制版本，用來證明「多智能體」確實必要；(ii) 在訓練集以外的網路規模與拓樸上測試泛化 (呼應 MetaBox 的 MGD 概念)；(iii) 回報訓練成本與推論時間；(iv) 用 IOHprofiler 做 anytime 比較；(v) 做消融實驗，拆解 agent 的每個決策維度各自的貢獻。
5. **量子的位置**：若想在 WSN 論文中加入量子元素，建議最多做成「附帶的誠實基準」(QUBO 化的叢集問題在 D-Wave 或 QAOA 模擬上的表現)，不要把它當成主要貢獻。

Caveats

- 部分引用結果屬於作者自述 (如 SE 在 CEC 2017 上的優勢、DRLH 的比較、D-Wave 新聞稿)，未經獨立重現。DeepHive 與部分 arXiv 論文尚未經過同儕審查。
- 量子領域變化快速：D-Wave 與 Flatiron 對「beyond-classical」結果的爭議仍在進行，[\(thequantuminsider\)](#) [\(dwavequantum\)](#) 未來可能出現新的硬體結果。本報告的結論是截至 2026 年 9 月的狀態。
- LLM 自動設計方向的論文多為 2024-2026 年的預印本或會議論文，排名與結論更迭很快，引用時應確認最新版本。
- 代理模型、大規模最佳化與理論方向在本報告中的篇幅較少，所引的是公認的代表作；若要深入，應另外查閱 IEEE TEVC 近年的專題綜述。